# Task2 报告

# 题目:用PySpark实现PAT排名(参考地址:<u>https://pintia.cn/problem-sets/16/problems/677</u>)

### 我用到的RDD算子如下:

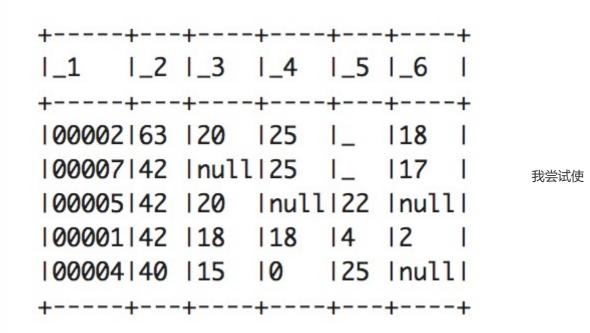
- 1. map
- 2. reduceByKey
- 3. aggregateByKey(zeroValue, mergeVal, mergeComb)
- 4. mapValues
- 5. sortBy
- 6. filter

## 用到的DataFrame基础函数如下:

- 1. createDataFrame
- 2. withColumn
- 3. 窗口函数rand().over

#### 遇到的疑惑:

在单用PySpark得到如下图后(离目标还差排序名次):



用了将RDD变成iterable的List,然后一行一行打印,边打印边添加序号,但是觉得这种做法在行数超大的时候应该不可取。于是想到了用Spark的DataFrame APIs,用里面的窗口函数rank(),最终得到了想

```
1 00002 63 20 25 _ 18
2 00007 42 _ 25 _ 17
2 00005 42 20 _ 22 _
2 00001 42 18 18 4 2
5 00004 40 15 0 25 _
```

### 代码如下:

要的结果:

```
<!--输入数据-->
info = [("00002", 2, 12), ("00007", 4, 17), ("00005", 1, 19), ("00007", 2, 25),
("00005", 1, 20), ("00002", 2, 2), ("00005", 1, 15), ("00001", 1, 18), ("00004", 1, 15), ("00001", 1, 18), ("00004", 1, 18)
3, 25), ("00002", 2, 25), ("00005", 3, 22), ("00006", 4, -1), ("00001", 2, 18),
("00002", 1, 20), ("00004", 1, 15), ("00002", 4, 18), ("00001", 3, 4), ("00001",
4, 2), ("00005", 2, -1), ("00004", 2, 0)]
<!--当ID和题号相同时,取出得分最高的。例如,"0001"号学生对于第一题提交了两次,分别得分15和
20, 那么应该取20作为"0001"号对于第一题的最终得分-->
high_marks = sc.parallelize(info).map(lambda line : ((line[0], line[1]),
line[2])).reduceByKey(max)
<!--将学号作为键, 题号和该题得分作为值(该步用map算子实现)-->
marks = sc.parallelize(high_marks.collect()).map(lambda line : (line[0][0],
(line[0][1], line[1])))
<!--将同一学生的不同题目的最高得分汇总在一起,这里有一个特殊情况就是: 当得分为-1时说明该题压根编
译不通过(要和题目得分为0区别开), 所以我们给该题得分赋为'_'(该步用aggregateByKey算子实现)-->
zeroValue = []
mergeVal = (lambda aggregated, el: aggregated + [el] if el[1]!=-1 else
aggregated + [(e1[0], '_')])
mergeComb = (lambda agg1,agg2: agg1 + agg2)
y = marks.aggregateByKey(zeroValue, mergeVal, mergeComb)
```

#### 现得到效果如下

```
<!--定义UDF, 该UDF意思是:对于某一学生的从未提交过的题目, 该题目得分赋为'_', 同时计算每个学生各个题目的总分和-->
def add_(x):
    sum = 0
    full_set = set([1, 2, 3, 4])
    s = set()
    for i in range(0, len(x)):
        s.add(x[i][0])
        if(x[i][1]!='_'):
            sum += x[i][1]
    x.insert(0, (0, sum))
    missing = full_set-s
    for e in missing:
```

```
x.append((e, '_'))
   return x
<!--按照总分和对RDD进行排序-->
def sort_(x):
   x = sorted(x, key=lambda a : a[0])
   return x
<!--用到mapValues和sortBy算子-->
y = y.mapValues(add_).mapValues(sort_).sortBy(lambda x : -x[1][0][1])
result = y.filter(lambda line : line[1][0][1]!=0)
<!--去掉题目编号,只显示总分和各题分数-->
def f(x):
   for i in range(0, 5):
       x[i] = x[i][1]
   return x
result = result.mapValues(f).map(lambda line : (line[0], line[1][0], line[1][1],
line[1][2], line[1][3], line[1][4]))
```

#### 现得到结果如下:

```
<!--将RDD转换为DataFrame以便利用DataFrame的窗口函数-->
from pyspark.sql.window import Window
from pyspark.sql.types import StructField, StructType, StringType
from pyspark.sql.functions import col, rank, desc
df = spark.createDataFrame(result, StructType([StructField("ID", StringType(),
False), StructField("sum", StringType(), False), StructField("course1",
StringType(), True), StructField("course2", StringType(), True),
StructField("course3", StringType(), True), StructField("course4",
StringType(), True)]))
<! --添加排序序号-->
df = df.withColumn("rank", rank().over(Window.orderBy(desc("sum"))))
df = df.select(["rank", "ID", "sum", "course1", "course2", "course3",
"course4"])
<!--再将DataFrame转换回RDD-->
rdd = df.rdd
def p(a):
   values = [str(a[i]) for i in range(0, len(a))]
    print(' '.join(values))
<!--按照特定打印格式对RDD iterable后的结果进行打印-->
[p(a) for a in rdd.collect()]
```

#### 现得到最终结果如下: